Le traitement du langage naturel par transformers illustré par un exemple pour la classification de texte

Cerisara Nathan, MPI

1er juin 2023

Sommaire

L'architecture Transformer

Schéma de l'architecture dans le cas de la génération :

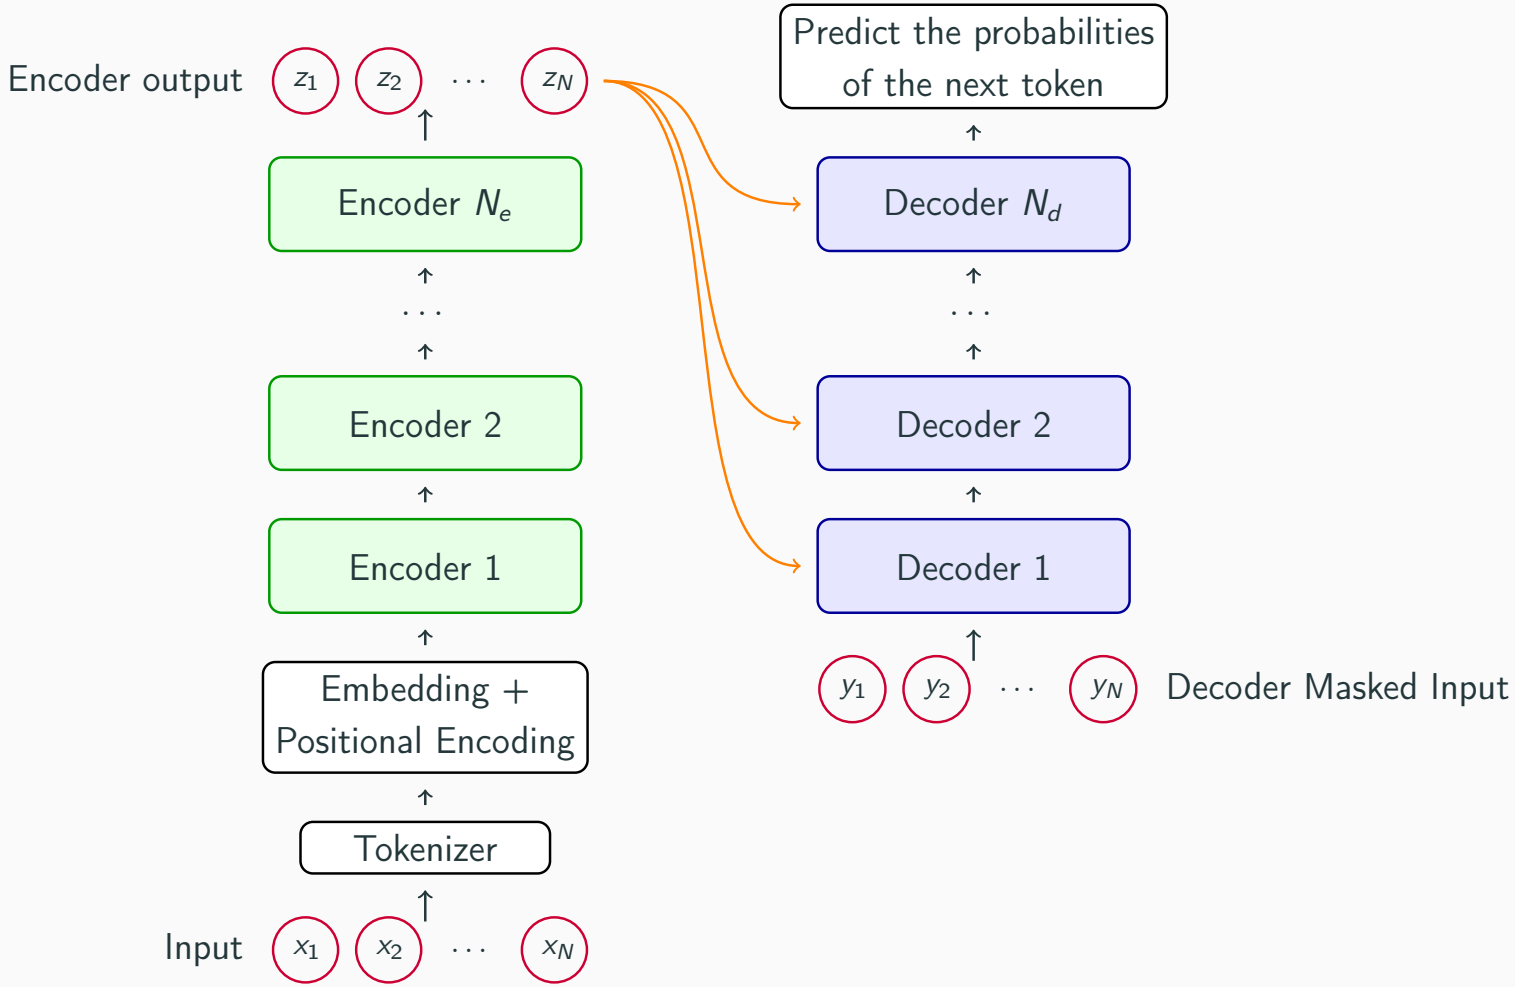

Vectorisation du texte : Tokenisation du texte

Tokenizer (bert-base-uncased)

Ex1 :

SENTENCE : “Neural Networks are so cool !”

TOKENS :
$[101, 15756, 6125, 2024, 2061, 4658, 999, 102, 0, \ldots, 0]$

[CLS] “neural” “networks” “are” “so” “cool” “ !” [SEP]

Ex2 :

SENTENCE : “Bonjour le monde !”

TOKENS :
$[101, 14753, 23099, 2099, 3393, 23117, 999, 102, 0, \ldots, 0]$

[CLS] “bon” “##jou” “##r” “le” “monde” “ !” [SEP]

Vectorisation du texte : Embeddings & Positional Encoding

Positional Encoding

$k \in [\![1, N]\!]$

$p_k = (f_k(1), f_k(2), \ldots, f_k(d_E))$

$f_k(i)$: position de chaque token dans la séquence

Token Embedding

$$t_k \longrightarrow \underbrace{(e_{k,0}, \ldots, e_{k,d_E})}_{\text{dimension } d_E}$$

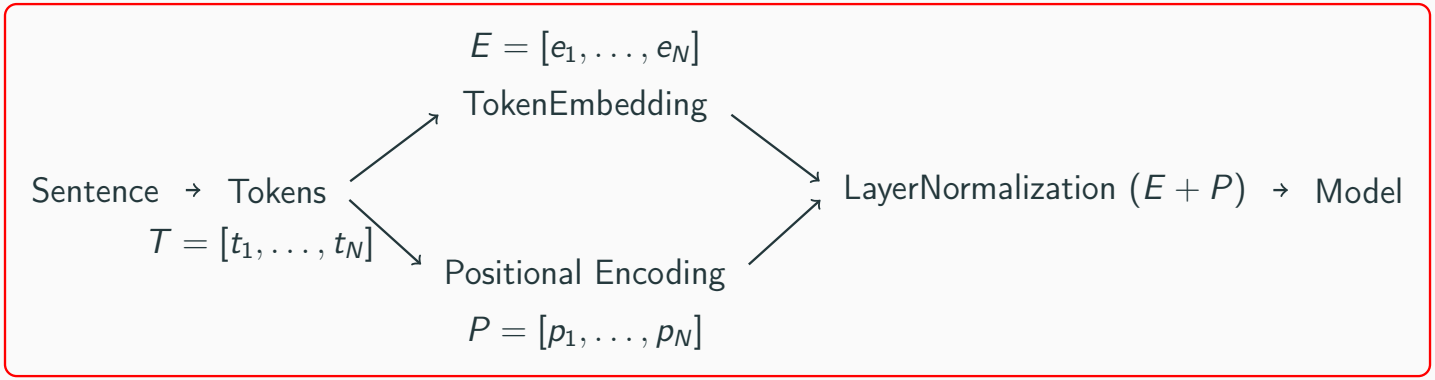

La partie Encodeur

Schéma d'un block de la partie Encodeur de l'architecture Transformer :

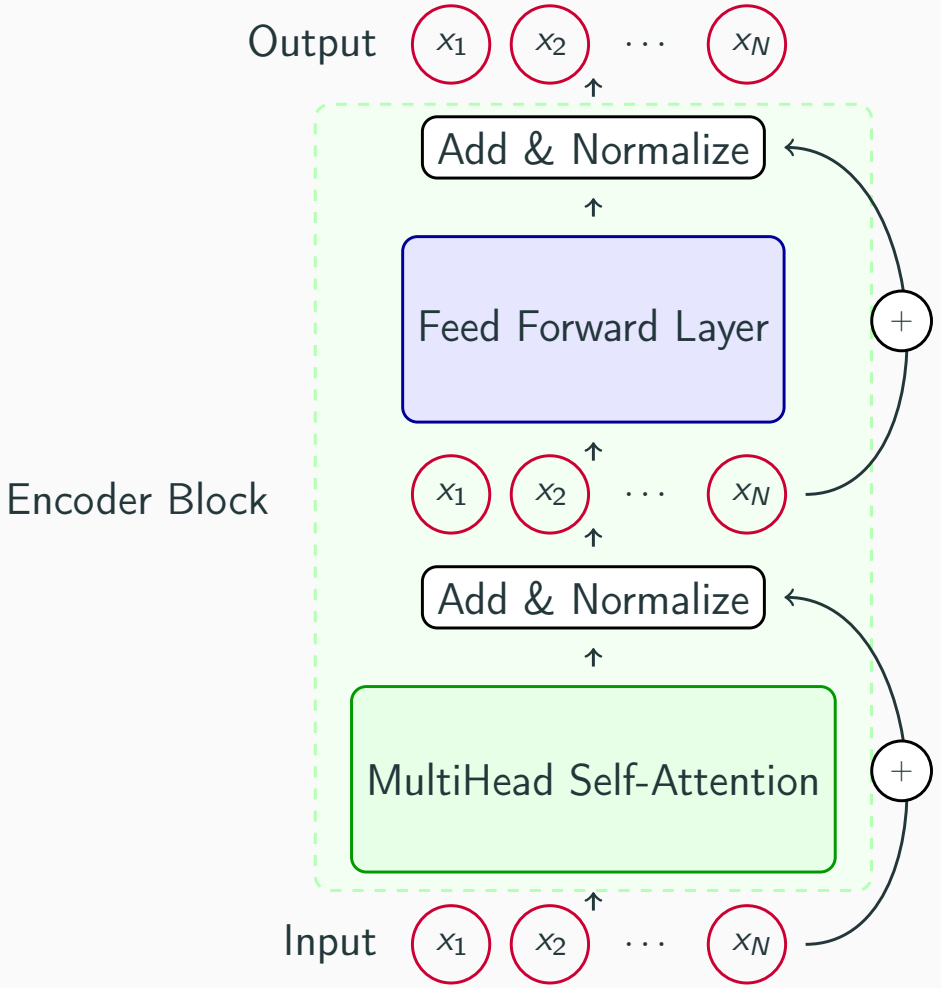

Matrice d'attention

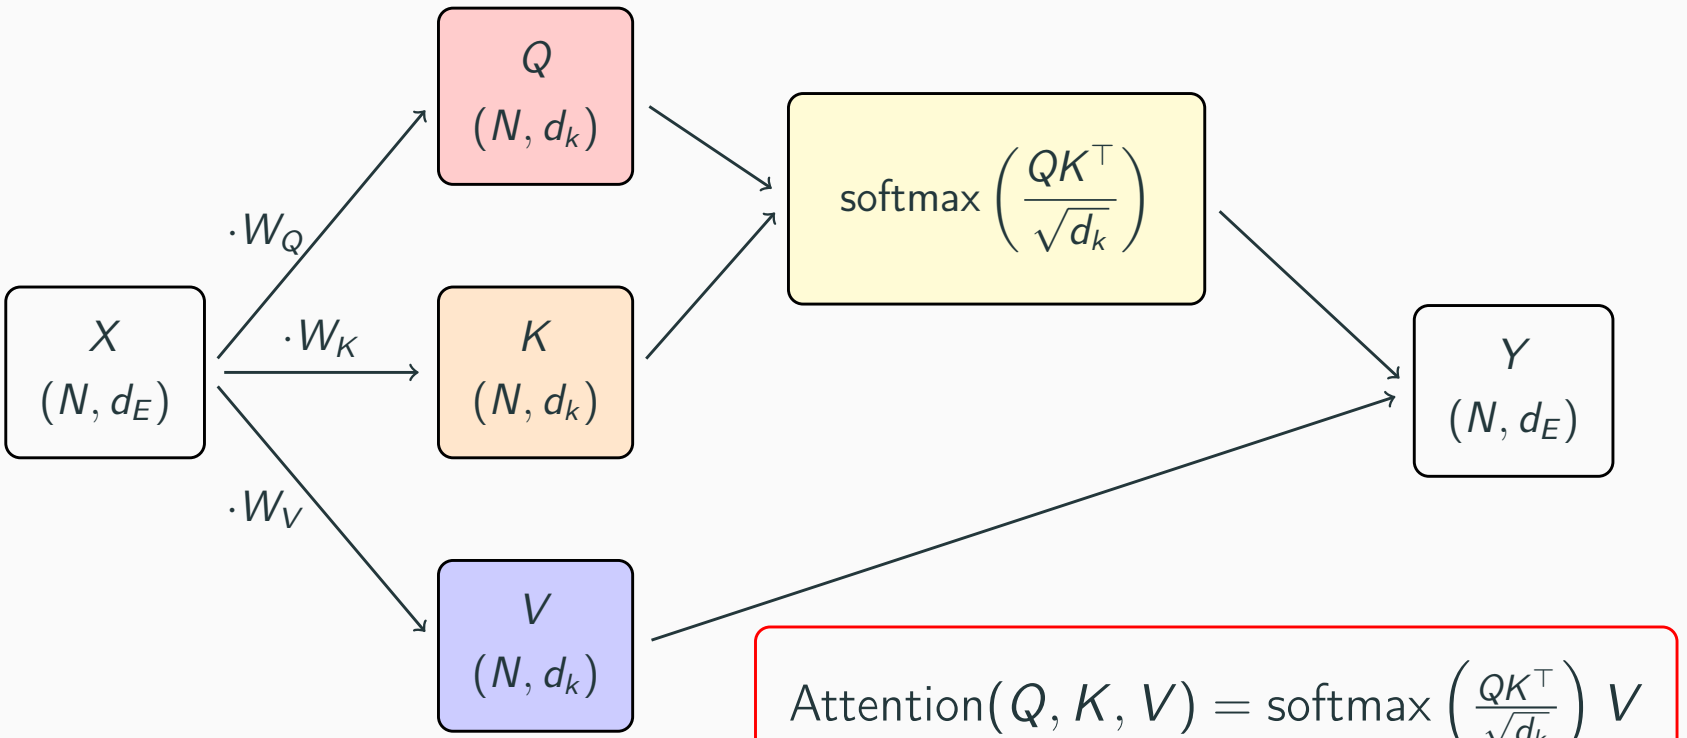

Le réseau Feed Forward

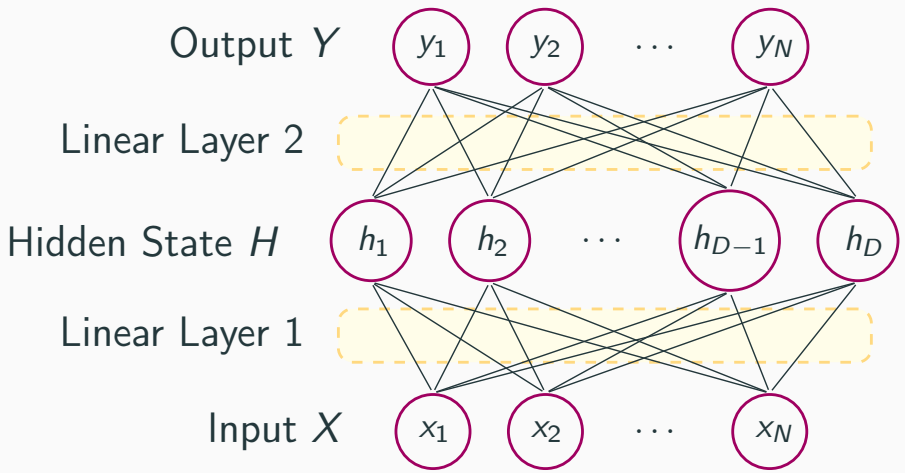

Couche linéaire :

$$X \mapsto X \cdot W^\top + B$$

Application Personnelle : Objectifs & Rapport à la ville

- **Objectif :**
  - Classification de texte
  - Sentiment : Négatif $\longleftrightarrow$ Positif
- **Rapport à la ville :**
  - Analyser les sentiments des habitants sur différents sujets
  - Peut servir à aider par exemple les mairies pour déterminer ce qui est le plus urgent

Le modèle BERT

- Architecture Transformer
- Plusieurs tailles de BERT (base, large)
- BERT base : 12$\times$ blocks encoder $\rightarrow$ 112M paramètres
- BooksCorpus (800M words) and English Wikipedia (2,500M words)
- Publié vers fin 2018 par des chercheurs de Google

La structure du réseau de neurone utilisée

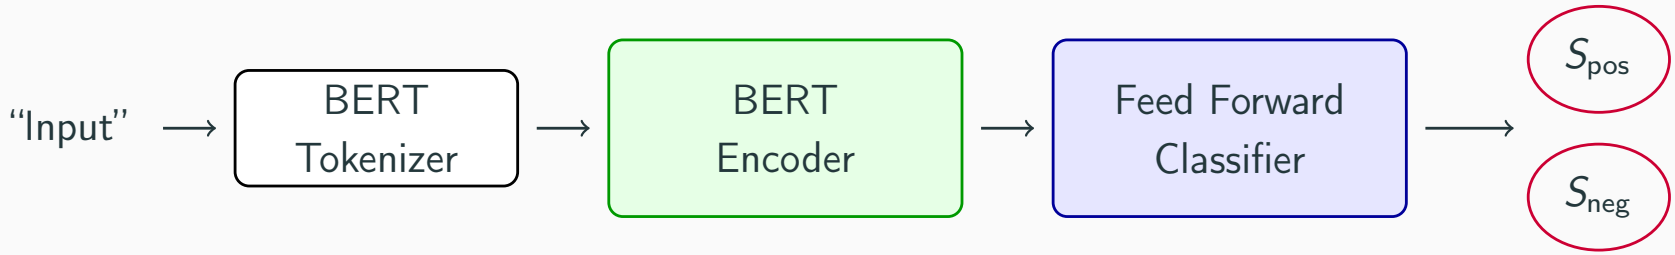

Les données et l'apprentissage

- **Données :** Twitter Sentiment140 (1.6 millions Tweets)
- Train : 50000, Test : 25000
- **Temps d'entraînement :** $\approx$ 5h
- **Algorithme d'apprentissage :** Adam optimizer (extension de la descente de gradient stochastique)
- **Fonction de Loss :** CrossEntropy

Les résultats

	My custom bert classifier			bertweet-base-sentiment-analysis		
	Positive	Neutral	Negative	Positive	Neutral	Negative
City (5784)	1940	**2006**	1838	1110	**2834**	1840
Cars (13104)	3272	4708	**5124**	1621	5466	**6017**
House (4681)	1501	**1675**	1505	720	**2297**	1664
Plants (1012)	197	371	**444**	81	430	**501**
Store (2087)	605	693	**789**	273	771	**1043**
Police (5834)	1496	**2323**	2015	482	**2797**	2555
Hospitals (4928)	1315	1634	**1979**	917	1765	**2246**

Annexes

Ce que l'on a vu :

- Architecture Transformer
  - Le block d'encodeur
  - Les matrices d'attention
  - Les réseaux Feed Forward
- Application Personnelle

Annexes / Ouvertures :

- Détails du code python
- Adam optimizer
- La fonction de loss
- La Normalisation par couche (LayerNorm)
- La partie décodeur
- Comparaison avec le modèle GPT
- Le théorème d'approximation universel
- Bibliographie

Annexes : Code python

```python
import torch.nn as nn

class Net(nn.Module):
    def __init__(self, dim_in, dim_out):
        super().__init__()
        #
        self.layer = nn.Linear(dim_in, dim_out)

    def forward(self, x):
        return self.layer(x)
```

Annexes : Adam Optimizer

Descente de gradient stochastique

Différences avec Descente de Gradient :

- Batch de données **vs** Dataset Entier
- Plus efficace en terme de calculs
- Ne se bloque pas forcément dans un minimum local
- Plus flexible pour le taux d'apprentissage

Adam : Adaptive Moment Estimation

- pour chaque itération : Moyenne mobile exponentielle des valeurs historiques du gradient
- Taux d'apprentissage adaptatif (individuellement pour chaque paramètre) sur la base du premier (Moyenne) et deuxième moment (Variance) du gradient
- Correction de biais
- Mise à jour des paramètres

Annexes : Fonction de loss

Fonction Cross Entropy

Soit $C_1, \ldots, C_N$ N classes . Soit $x = (x_1, \ldots, x_N)$ la sortie du modèle. Soit v l'indice de la vraie classe.

pour chaque $i \in [\![1, n]\!]$,

$$E_i = -\log\left(\frac{e^{x_v}}{\sum_{k=1}^{N} e^{x_k}}\right)$$

Donc au final $CE(x, v) = \frac{1}{N}\sum_{i=1}^{N} E_i$

Annexes : LayerNormalization

Entrée : Tensor X de dimensions : (batch_size, sequence_length, embedding_size)

Opérations :

- La moyenne $E(X)$ et la Variance $V(X)$ (sur la dimension de l'embedding de l'entrée)
- Normalization :

$$N_X = \frac{X - E(X)}{\sqrt{V(X)}}$$

- Mise à l'échelle et décalage :

$$N_x \cdot \alpha + \beta$$

$$\text{LayerNorm(X)} = \frac{X - E(X)}{\sqrt{V(X) + \varepsilon}} \cdot \alpha + \beta$$

Annexes : Partie décodeur de l'architecture transformer

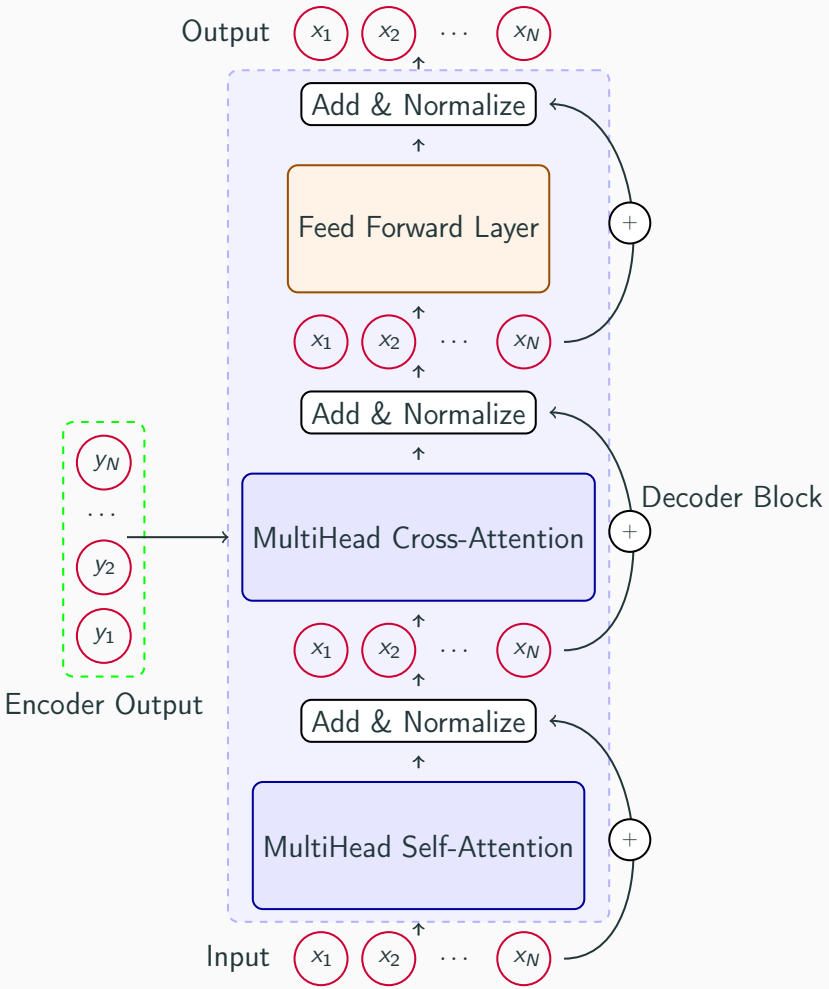

Annexes : Comparaison avec le modèle GPT

Annexes : Le théorème d'approximation universel

Enoncé : Les transformateurs sont des approximateurs universels des fonctions continues de séquence à séquence sur un domaine compact.

Preuve :

Annexes : Bibliographie

- Pytorch documentation
- “Attention is all you need”, Google Research, 2017
- “BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding”, Google AI Language, 2018
- “Improving Language Understanding by Generative Pre-Training” OpenAI, 2018
- “ARE TRANSFORMERS UNIVERSAL APPROXIMATORS OF SEQUENCE-TO-SEQUENCE FUNCTIONS ?”, Google Research, 2020